

基于季节锚定组合与层级份额收缩的零售销售额预测与经营策略研究

摘要

零售销售明细同时存在强右尾、一单多行和仅 48 个月的短序列；若四问各用一套口径，订单计数、驱动判断、总量预测与资源分配将相互矛盾。本文沿“校正统计实体—筛选稳定关联—锁定预测模型—约束层级分配”推进，并以朴素基线、时间外验证和参数扰动检验各环节。

对于问题 1：直接把明细行当订单会得到 9800 单，而按订单号去重仅有 4921 单，高估 99.15%。为此构建“订单—月份双口径稳健画像”：原尺度保留销售总额，订单层用归并与分位数刻画典型交易，月份层识别季节结构。结果显示，最高一成明细贡献 60.40% 的销售额，第四季度占 38.52%，销售兼具头部集中与年末后置特征。

对于问题 2：一张订单可能包含多个品类，整单汇总会丢失产品信息，逐行检验又会制造伪独立。因此提出“订单簇置换的双证据因子筛”，在明细层保留产品结构，但按订单整簇完成检验、重采样与损失计算，并用跨年方向和参数网格复核。产品历史价值层、产品大类和产品子类在 81/81 组扰动中均入选；区域仅入选 54/81 组，故降为次级信号。同一 2025 年时间外样本上，订单等权 $\log_{1p}$ MAE 由 1.105920 降至 0.590432，改善 46.61%。

对于问题 3：训练期仅 36 个月、测试期仅 12 个月，不宜在封存结果上反复择模。本文在训练期锁定“季节锚定—偏差校正组合预测”，以季节朴素保留去年同月结构，用阻尼 ETS 与谐波岭修正水平、趋势和季节形状，并校正对数反变换偏差。2025 年封存测试中，组合相对季节朴素将 MSE、MAE 和 MAPE 分别降低 60.42%、37.95% 和 34.17%，四个季度 MAE 均胜出，九组权重扰动下部署结论不变。

对于问题 4：各层级独立预测会造成产品大类与子类无法回加，故采用“总量锚定的层级份额收缩”：按稳定性融合长期、近期与同月份份额，再以父级份额乘条件子类份额保持协调。2025 年五维平均份额 WAPE 由固定份额基线的 39.585% 降至 29.015%，各维度最大加总误差不超过 5.82×10^{-11} 。2026 年销售额点预测为 791951.82，全年可加总风险边界为 [454803.67, 1379541.60]；2025 年封存测试的 95% 经验区间覆盖率仅为 83.33%，故该边界不作严格概率保证，Technology、Phones 和 Storage 可优先配置，但仍需保留悲观情景下的规模防守。

四问依次回答“数什么、信什么、怎样预测、如何分配”，把数据口径、模型精度和策略强度约束在同一证据链内。

关键词：稳健统计；订单簇置换；组合预测；层级份额收缩；零售经营

目录

一、 从订单明细到经营决策的任务链 1

二、 零售明细的数据陷阱治理与假设边界 1

三、 订单—月份双尺度的销售结构画像 3

四、 时间—地理—产品—客户—物流的双证据驱动识别 7

五、 36 个月训练窗下的季节锚定组合预测 11

六、 总量一致的 2026 层级预测与经营动作 16

七、 从数据口径到决策稳健性的跨问题检验 20

八、 零售预测结论、适用边界与推广 21

参考文献 22

一、从订单明细到经营决策的任务链

1.1 问题重述

问题 1：核算销售额分布与去重业务指标，刻画时间、地理、产品、客户和物流结构。

问题 2：检验五类因素与销售额的稳定关联，区分增长驱动、经营短板及其解释边界。

问题 3：用前三年训练月度预测模型，在后一年封存数据上检验误差与泛化能力。

问题 4：预测下一年月、季和全年销售额，完成业务层级分解并形成经营动作。

1.2 月度目标与双层证据链

四问共用订单商品明细，却对应两种分析尺度：问题 1、问题 2 保留商品、客户、区域和发货标签，用于解释销售结构；问题 3、问题 4 按下单日期聚合自然月销售额，用于检验外推并配置经营总量。月度预测给出统一总量锚，明细层估计的稳定因素与收缩份额再把总量还原到各业务层级，因而任务链依次完成口径治理、驱动识别、总量预测和策略分解。

我们最初按任务提示把序列视为约 47 个月，重新解析日期并逐月聚合后确认研究期有 48 个连续有单自然月，故采用 36 个训练月和 12 个测试月。年度数据不足以训练并留出检验期，日度数据又会放大订单到达噪声；月度尺度既保留季节位置，也能直接汇总季度结果。

这条链路中的每次改造都来自实际复核：问题 1 曾把明细行直接视为订单，发现订单多行后改按订单号去重；问题 2 曾压缩为一单一行，但多品类订单会混合产品效应，遂保留明细并按订单成簇检验；问题 3 曾考虑自动定阶的大参数网格，短训练窗促使我们改用季节锚约束低自由度模型；问题 4 曾尝试为各细层单独建模，稀疏月与加总矛盾使方案转为总量锚定的份额收缩。

二、零售明细的数据陷阱治理与假设边界

2.1 从原始字节到可计算业务实体

原始文件不能依赖软件自动识别：其实际编码为 GBK，订单日期与发货日期均按 DD/MM/YYYY（Python 格式 %d/%m/%Y）解释。若误用 Latin-1，姓名和商品名会出现乱码；若沿用美式月日顺序，部分日期即使能够解析也会被静默交换。数据载入后统一转存为 UTF-8，日期解析则固定格式，使后续月份归属与履约天数都建立在同一时间口径上。

业务实体审计比类型转换更关键。原表含 9800 条商品明细，却只对应 4921 个不同订单号，因此 **Row ID** 只作追溯键，订单规模按 **Order ID** 去重，常量 **Country** 不进入因素模型。产品聚合固定使用 **Product ID**：有 32 个产品编号对应多个名称，也有 16 个名称对应多个编号，冲突只标记而不凭名称合并。明细销售均值为 230.769，中位数仅为 54.49，故大额记录保留在原尺度总量中，典型水平与因素比较改用稳健统计或对数尺度。

排除唯一行号后，**Row ID** 为 3406 与 3407 的记录其余字段完全相同。主口径删除 3407 并保留 3406，得到 9799 条明细；敏感性口径保留原表，二者销售总额相差 281.372。这种处理只针对缺少数量字段佐证的唯一疑似复制组，后续总量结论仍用保留口径复核。

图1给出治理后的两条分析支路。明细解释层保留产品、客户、区域与发货模式，并以订单号形成重采样簇；月度预测层只按订单日期汇总销售额。发货日期异常另设双口径，不反向改变销售额或月份归属。




图 1 零售明细治理与分析口径分流

2.2 物流日期的双口径隔离

发货日期早于下单日期的异常集中在 42 条明细、20 个订单，均来自年末下单而发货年份写成早年。我们最初考虑把这些发货年份统一修正后作为唯一口径，但发现改为后一年后履约天数虽全部落在 3 至 7 天，年份仍未经企业确认，因此改用“年份修正”和“异常置缺”并行的双口径。设第 i 条明细的下单日为 d_i^O ，修正发货日与置缺发货日分别为 $d_i^{S,c}$ 、 $d_i^{S,m}$ ，履约天数定义为

$$L_i^c = d_i^{S,c} - d_i^O, \quad L_i^m = d_i^{S,m} - d_i^O. \quad (1)$$

其中, L_i^c 利用年份修正后的完整记录, L_i^m 在异常行取缺失。两种处理均不修改 **Order Date**、**Sales**、**Order ID** 与 **Ship Mode**, 实际校验得到总销售额差、总订单数差及各发货模式销售额差均为零。因此物流口径只约束履约关联的可信度, 销售画像、驱动筛选的非物流字段与月度预测不会随修正选择而变化。

2.3 贯穿四问的假设与影响边界

表1把各问共用的假设压缩为可审计边界。每条假设都对应数据结构或字段缺口; 一旦边界被突破, 受影响的结论应回退到表中所列范围, 而不是把局部口径扩展成普遍事实。

表 1 建模假设、数据依据与影响边界

假设	本题依据	影响边界
销售可加, 订单为最小业务簇	一单可含多条商品明细	总量按明细求和, 重采样与切分按订单成簇
无记录月表示该层级无销售	研究期按订单日期形成连续月度记录	只适用于当前数据被视为全量明细; 抽样数据须重估零填充波动
治理判断保留敏感性口径	疑似复制缺少数量佐证, 异常年份缺少企业确认	重复处理须双口径复核; 日期修正只影响物流统计
历史顺序可用于外推	计划采用早期训练、后期封存检验	编码、参数与阈值只能由预测时点之前的数据估计
2026 季节位置与份额机制延续, 结构突变时触发滚动重估	季节总量以历史同月为低方差锚, 层级份额由近期、同月与长期结构收缩得到	仅支持 2026 年既有类别与相近经营环境的外推; 若季节次序、类别集合或份额路径突变, 须滚动重估总量模型与收缩权重
历史类别构成分解集合驱动只作关联解释	层级预测在既有业务类别内分配总量 数据缺少数量、折扣、利润、成本、促销和库存	新类别须增设“其他/新层级”并重新归一化 不推出利润最优、价格弹性、安全库存件数或标签干预收益

这些边界决定后文的用词强度: 产品与区域结果用于描述销售结构和预测信息, 客户与物流层级可用于容量配置; 任何经营建议都须经过时间外验证和敏感性检查, 不能由单次分类均值直接推出干预收益。

三、订单一月份双尺度的销售结构画像

3.1 双尺度口径与稳健统计量

原始表的一行对应订单中的一种商品, 销售总量应在明细层累加, 交易规模则应先按订单归并。设第 i 条明细的销售额为 x_i , 订单 o 所含明细集合为 $\mathcal{I}_o$, 月份 t 所含明细集合为 $\mathcal{I}_t$, 定义

$$S = \sum_i x_i, \quad A_o = \sum_{i \in \mathcal{I}_o} x_i, \quad M_t = \sum_{i \in \mathcal{I}_t} x_i.$$

(2)

其中， S 表示全期销售总额， A_o 表示订单销售额， M_t 表示月销售额。治理后的数据含 9799 条商品明细，总销售额为 2261255.411，按订单号去重得到 4921 张订单，标准化客户编号后有 793 位有效客户，按产品编号计有 1861 种产品。

本题明细销售额的右尾很长，均值不宜单独承担“典型交易”的解释。我们同时保留均值以守住总量可加性，以中位数描述典型水平，并用高位样本销售占比衡量集中程度 [1]。两个业务尺度的结果列于表2。

表 2 明细层与订单层的稳健销售统计

统计尺度	观测数	均值	中位数	最高一成占比
商品明细	9799	230.764	54.480	60.40%
订单汇总	4921	459.511	151.930	53.14%

明细均值约为中位数的 4.24 倍，偏度为 12.983，基尼系数为 0.744；订单归并后偏度仍为 8.347，说明长尾不是同单多行造成的表面现象。图2在原尺度经验分布中保留极端销售额，又用 $\log(1+x)$ 展开主体区域；变换后的明细偏度降至 0.281，后续涉及分布比较时据此采用对数或秩统计，而业务总额仍使用原尺度。




图 2 销售额原尺度经验分布与对数密度

第一版统计口径直接用 9800 条明细作为订单数，后来核对发现不同订单号只有 4921 个，朴素口径会高估 99.15%，因此改为按订单号去重，并另算订单层分布。长尾结论也未依赖单一阈值：四分位距倍数在 1.0 至 3.0 间变化时，高值明细仍贡献 70.01% 至 50.93% 的销售额，故大额记录只标记而不删除。

3.2 月度增长与年末季节结构

订单日期覆盖的 48 个自然月均有销售记录，月度聚合既保留日历周期，又避免日度稀疏波动遮蔽经营节奏。按月份 m 汇总跨年平均销售额 $\bar{M}_m$ ，以全期月均值 $\bar{M}$ 为基准定义季节指数

$$I_m = \frac{\bar{M}_m}{\bar{M}}. \tag{3}$$

其中， I_m 大于单位水平表示该日历月通常处于旺季，小于单位水平表示通常处于淡季。图3把原始月销售额、周期趋势、季节分量和剩余波动放在同一视图中，便于区分规模扩张与重复出现的月内节奏。




图3 月度销售趋势、季节分量与剩余波动

年度总量在 2023 年下降 4.20%，随后于 2024 年和 2025 年分别增长 30.64% 与 20.30%；对应订单数由 2022 年的 947 张增至 2025 年的 1661 张，近两年的扩张因而不只是少数大额明细抬升。季度结构的差异更稳定：第四季度占全期销售额的 38.52%，第一季度仅占 15.53%；分年复核得到各年第四季度与第一季度销售额之比均在 2.28 至 2.90 之间。月份层面，十一月、十二月和九月的全期份额依次为 15.49%、14.22% 和 13.27%，二月份仅为 2.63%，库存与履约准备应覆盖秋季启动和年末集中释放两个阶段。

3.3 份额与波动的联合画像

只按销售份额排序会忽略小规模层级的跳跃风险。对维度 g 的层级 k ，以完整月份集合 $\mathcal{T}$ 计算

$$p_{gk} = \frac{\sum_{t \in \mathcal{T}} M_{gkt}}{S}, \quad CV_{gk} = \frac{\text{sd}(M_{gk1}, \dots, M_{gkT})}{\text{mean}(M_{gk1}, \dots, M_{gkT})}. \quad (4)$$

其中， p_{gk} 是销售份额， CV_{gk} 是月销售额变异系数。某层级无明细的月份在 M_{gkt} 中记为零，因为研究对象是完整经营期，而不是“发生过销售的月份”子样本。

我们最初直接在各层级已有的月记录上计算标准差，但分组汇总会省略无销售月份，从而压低小层级波动；因此改为把每个层级与完整 48 个月做笛卡尔展开，再对缺口补零。图4保留全部结构层级，用横轴、纵轴和气泡面积分别表示份额、相对波动和明细量。




图4 多维销售份额、月度波动与样本规模

产品大类中 Technology、Furniture 与 Office Supplies 的份额分别为 36.59%、32.21% 和 31.20%，区域上 West 与 East 合计占 61.00%；客户细分以 Consumer 的 50.77% 为主，发货模式以 Standard Class 的 59.28% 为主。份额较高不等于波动较小：East 的变异系数为 0.767，高于 West 的 0.547；Home Office 为 0.799，高于 Consumer 的 0.575。产品子类 Supplies 仅占 2.05%，变异系数却达到 2.026，其不稳定性会在细层级独立外推时被放大。这些份额和波动描述回答“销售来自哪里、起伏有多大”，不能单独证明某个标签导致销售增长；驱动判断仍需下一章的效应量、时间外重要性与跨年稳定性共同约束。

四、时间—地理—产品—客户—物流的双证据驱动识别

问题 2 要区分“组间销售分布有差异”与“该因素能解释未来订单”这两个命题。治理后的样本含 9799 条明细，但只对应 4921 个订单，同一订单中的商品行并不独立。因为本题同时存在强右尾和订单内相关，所以我们保留商品明细以免抹去产品结构，又把检验、重采样和验证损失统一提升到订单簇层面。多维字段进入两条相互独立的证据链：秩检验回答分布差异，时间外置换回答预测增量，跨年方向和参数翻转审查负责拦截偶然信号。

4.1 订单簇稳健检验与时间外预测证据

销售额的稳健尺度定义为

$$Y_i = \log(1 + S_i), \quad (5)$$

其中， S_i 为第 i 条商品明细的销售额， Y_i 为其对数销售额。该变换不改变秩次，却压缩大额明细对预测损失的支配程度。对任一含 k 个水平的因素 F ，以平均秩偏离构造 Kruskal–Wallis 统计量 [2]，并用 epsilon 平方描述差异规模：

$$H_F = \frac{12}{n(n+1)} \sum_{g=1}^k n_g \left(\bar{R}_g - \frac{n+1}{2} \right)^2, \quad \varepsilon_F^2 = \max \left\{ 0, \frac{H_F - k + 1}{n - k} \right\}. \quad (6)$$

其中， n_g 和 $\bar{R}_g$ 分别表示第 g 组的明细数与平均秩， n 为总明细数。普通渐近检验会把每条商品行视为独立观测，本题则只在明细数相同的订单之间交换完整标签块，并按订单整簇 bootstrap；多个因素的显著性再用 BH 方法控制假发现率 [3]。该设计来自一单多行的实际结构，而不是对普通检验作形式替换。

客户和产品编号具有高基数，直接独热编码会形成稀疏特征，全样本目标编码还会把当前销售额写回自身。对实体 e 在日期 t_i 出现的明细，本文仅使用严格早于该日的历史记录，定义平滑历史价值

$$\tilde{\mu}_{e,i} = \frac{\sum_{j:e_j=e, t_j < t_i} Y_j + \lambda \mu_{< t_i}}{|\{j : e_j = e, t_j < t_i\}| + \lambda}. \quad (7)$$

其中， $\mu_{< t_i}$ 为 t_i 之前的全局对数销售均值， λ 为向全局历史水平收缩的先验强度。严格使用 $t_j < t_i$ ，使同日其他商品和未来年度信息均不能进入当前特征；产品历史价值层的分位边界也只由训练期估计。

第二条证据采用绝对误差损失的低自由度梯度提升树 [4]。训练期含 6541 条明细和 3260 个订单，时间外验证期含 3258 条明细和 1661 个订单，两个时期的订单编号没有交叉。2025 年的角色是“被 81 组翻转诊断重复使用的时间外验证集”，只用于检查因素身份和重要性方向是否翻转，不据其误差另选主设定。严格历史特征按订单到达逐日更新；若经营场景要求在年初一次性预测全年，需另行固定历史截止日验证，不能直接沿

用该逐日可得口径。设验证订单 c 含 m_c 条明细，因素组 G 被整簇置换后的预测为 $\hat{Y}_i^{\pi_G}$ ，则其时间外重要性为

$$\Delta_G = \frac{1}{C} \sum_{c=1}^C \frac{1}{m_c} \sum_{i \in \mathcal{O}_c} \left(\left| Y_i - \hat{Y}_i^{\pi_G} \right| - \left| Y_i - \hat{Y}_i \right| \right). \quad (8)$$

其中， $\mathcal{O}_c$ 为订单 c 的商品行集合， C 为验证订单数。 $\Delta_G > 0$ 表示破坏该因素后订单等权误差上升；先在订单内平均再对订单平均，可防止多商品订单自动获得更高权重。实际履约天数发生在下单之后，因此不进入预测模型，物流维只保留下单时已知的发货模式。

图5连接了五维字段、两条证据、跨年检验与参数审查。因素需同时满足 FDR 统计证据、稳定正的时间外重要性和跨年方向要求，基准设置入选后还要在全部参数组合中不翻转，才被认定为稳定核心。




图 5 五维因素的双证据筛选与经营使用路径

4.2 产品因素的双证据强度

图6把效应量、FDR 显著性与最终层级放在同一尺度上。产品历史价值层的效应量最高，产品子类次之，产品大类仍保留清晰的组间秩差；区域虽然达到统计显著，但效应量接近于零，显著性并不等同于经营影响强。



图 6 五维因素的效应量、显著性与结论层级

表 3 核心产品因素与区域信号的证据对照

因素	ϵ^2	Δ MAE	跨年同向率	网格入选
产品历史价值层	0.5630	0.9988	1.00	81/81
产品子类	0.4432	0.0301	1.00	81/81
产品大类	0.2252	0.0258	1.00	81/81
区域	0.0023	0.0005	0.75	54/81

表3显示，产品维内部也有明显层次。产品历史价值层的时间外增量远高于类别标签，说明同一产品过去形成的销售层级比静态类别更能区分明细销售额；子类效应又高于大类，表明具体产品结构包含粗粒度分类未表达的信息。整组置换产品维后，订单等权对数 MAE 增加 1.1092，其订单簇 bootstrap 区间为 [1.0837, 1.1326]，产品信息因而构成五维解释中的主轴。

同口径朴素基线只用训练期普通 ANOVA 筛选和分类均值预测，在相同验证订单上的 MAE 为 1.1059；双证据模型降至 0.5904，相对改善 46.61%。图7进一步显示三项产品因素在统计、时间外、跨年和参数审查中保持同向，而区域只在前三类证据下看似完整，参数稳健性并未填满。

全网格稳定核心：产品历史价值层、产品大类、产品子类					最终层级
	FDR稳健检验	时间外重要性	跨年方向	81组参数稳健性	
产品历史价值层				81/81 (100%)	核心
产品子类				81/81 (100%)	核心
产品大类				81/81 (100%)	核心
区域				54/81 (67%)	次级
州			—	0/81 (0%)	未入选
客户历史价值层	—	—		28/81 (35%)	未入选
发货模式	—	—		22/81 (27%)	未入选
客户细分	—	—	—	0/81 (0%)	未入选
季度	—	—	—	0/81 (0%)	未入选
月份	—	—	—	0/81 (0%)	未入选
年	—	—	—	0/81 (0%)	未入选
履约天数（异常置缺）	—	—		0/81 (0%)	事后变量

马赛克列表按81组入选比例切分：三项产品因素均填满；区域前三类证据虽一致，但仅填满2/3，因此降为阈值敏感次级信号。

图 7 候选因素在多类证据中的一致性

4.3 阈值翻转、经营短板与解释边界

我们最初采用四年方向一致率不低于 0.75 的判据，区域与三项产品因素一同进入基准清单；但把阈值提高到 1.00 后，区域因同向率只有 0.75 而退出，核心身份发生翻转。因此返工没有选择能保留原结论的单一参数，而是把历史平滑、树复杂度和跨年判据组成 81 组审查：三项产品因素均为 81/81 入选，区域仅为 54/81，且网格中的重要性方向会改变。区域据此降为阈值敏感的次级地理信号，只能用于分层观察，不能与产品核心并列。

经营矩阵把稳定因素的销售份额与同比变化交叉。图8中，Technology 在验证年度占 37.31% 且同比增长 21.36%，可作为产品布局中的增长承接对象；Machines 份额为 6.03%，却同比下降 22.11%，属于规模不低但正在收缩的产品短板。West 虽表现为 34.36% 的份额和 35.98% 的增长，仍只能作为容量配置线索，因为区域因素没有通过全网格核心条件。




图8 子品类与区域的销售贡献—增长象限

时间、州、客户和物流标签未进入稳定核心，并不等于这些字段没有管理价值，而是现有数据不足以支持稳定的增销解释。模型在原尺度上的 WAPE 为 77.69%，它适合识别相对驱动和结构短板，不承担单笔金额精确预测。数据还缺少数量、折扣、价格、利润、促销和库存，故本节的“驱动”仅指稳健关联与预测信息；后续经营策略应把产品核心用于资源优先级，把区域信号用于小范围分层验证，不能把标签相关性改写成因果收益。

五、36 个月训练窗下的季节锚定组合预测

5.1 预测口径与短序列约束

本问把订单明细压缩为自然月总销售额。设第 t 个月的明细集合为 $\mathcal{I}_t$ ，月度目标写为

$$y_t = \sum_{i \in \mathcal{I}_t} Sales_i. \quad (9)$$

其中， $Sales_i$ 为第 i 条明细的销售额， y_t 为当月全部明细的销售额之和。逐月复核得到从 2022 年 1 月至 2025 年 12 月连续有值的 48 个月序列；前 36 个月用于建模，后 12 个月在锁模前保持封存。

训练期月销售额均值为 42755.650，中位数为 34238.702，取值跨越 4519.892 至 95739.121，变异系数为 0.539。本题每个日历月只有 3 个训练观测，却要表达 12 个月季节循环，所以自由度必须让位于季节结构；只依赖近期水平会抹去年末旺季，为每个月单独估计参数又会把偶然波动当作规律。

我们曾检查能否把 $\log(1 + y_t)$ 解释为正态化处理，但训练期偏度由原尺度的 0.588 变为对数尺度的 -0.954，对称性并未改善。因此，对数变换只用于压缩大额月份对参数

估计的支配，季节朴素、组合权重与误差评价仍在销售额原尺度上完成。令

$$z_t = \log(1 + y_t), \quad S = \frac{1}{n_r} \sum_{t \in \mathcal{R}} \exp(\hat{\varepsilon}_t), \quad \hat{y}_t = \max\{0, \exp(\hat{z}_t)S - 1\}. \quad (10)$$

其中， z_t 是压缩尺度序列， $\mathcal{R}$ 是可用拟合残差集合， S 是 Duan 型 smearing 因子 [7]，最后一式同时修正指数反变换偏差并守住销售额非负边界。

5.2 季节锚与低自由度修正模型

季节朴素直接复制上一年同月，是本题方差最低且业务含义最清楚的硬基线 [9]。三月移动平均与历史同月均值只作交叉印证：前者不含年度季节位置，后者会削弱近期水平变化；主组合只保留季节朴素作为稳定锚。

阻尼 ETS 用局部水平、受限趋势和月度季节项修正季节锚 [5]。因为训练序列只覆盖 3 个完整周期，所以趋势不能按预测步长无限外推，仅保留与本题预测直接相关的阻尼递推式

$$\hat{z}_{T+h} = \ell_T + \left(\sum_{j=1}^h \phi^j \right) b_T + q_{T+h-12k}. \quad (11)$$

其中， ℓ_T, b_T, q_t 分别为训练终点的水平、趋势与月度季节状态， k 使季节下标落入最近的已估计周期。入选配置取 $\phi = 0.98$ ，使远期趋势增量逐渐收敛。

谐波岭回归用少量正余弦项表达平滑季节形状，并用岭惩罚压住短样本中的系数摆动：

$$z_t = \beta_0 + \beta_1 u_t + \sum_{k=1}^K \left[a_k \sin\left(\frac{2\pi kt}{12}\right) + c_k \cos\left(\frac{2\pi kt}{12}\right) \right] + e_t, \quad u_t = \frac{t - (n-1)/2}{n-1}, \quad (12)$$

其中， u_t 为训练窗内的缩放时间， K 为谐波阶数， a_k, c_k 描述季节波形。参数由

$$\hat{\theta} = \arg \min_{\theta} \left\{ \sum_t (z_t - x_t^T \theta)^2 + \lambda \sum_{j \neq 0} \theta_j^2 \right\} \quad (13)$$

求得，其中截距不受惩罚；岭惩罚对短样本中的共线系数作稳定收缩 [6]。滚动回测选出 $K = 2$ 、 $\lambda = 1.0$ ，即只用平滑低频季节项修正同月锚。

低阶 SARIMA 只补充局部与季节相关信息 [9]。我们最初考虑自动定阶和更大的参数网格，但 36 个训练点还要在 24 至 35 个月的短窗口内重复拟合，选择偏差与计算量都会被放大，因此只比较 4 个低阶结构；其中一个候选在训练截止 2024 年 2 月时产生非有限预测，脚本将该候选整项判为无效，没有用替代值掩盖失败。

5.3 滚动回测与多步调参

参数选择只发生在训练期内部，采用滚动起点评价以保持预测时序 [9]。最小训练窗取 24 个月，让首个起点至少看见两个完整季节周期；起点从 $o = 24$ 滚动至 $o = 35$ ，

每次只使用 $y_1, \dots, y_o$ ，一次预测其后最多 12 个月，共形成 12 个起点和 78 条预测记录。

为了不让记录较多的短步预测淹没长步表现，候选 j 在步长 h 、指标 m 上先相对季节朴素标准化，再对重点步长等权：

$$r_{jhm} = \frac{L_{jhm}}{L_{SN,hm}}, \quad Score_j = \frac{1}{4} \sum_{h \in \{1,3,6,12\}} \frac{1}{3} \sum_{m \in \{MSE, MAE, MAPE\}} r_{jhm}. \quad (14)$$

其中， L_{jhm} 是模型 j 的对应损失， r_{jhm} 消除指标量纲， $Score_j$ 同等看待近、中、远期。第 12 步只有 1 条回测记录，所以它用于约束方向，不单独决定模型。

各模型族先按该评分锁定一项配置，随后才学习组合权重。训练期全步长误差列于表4，组合在 78 条记录上的 MAE 为 10078.790、MAPE 为 17.485%，均低于单个候选。

表 4 训练期滚动回测的全步长误差

模型	RMSE	MAE	MAPE (%)
季节朴素	16615.115	13873.441	25.049
阻尼 ETS	14380.020	11954.674	21.023
谐波岭回归	21875.662	15168.566	24.290
低阶 SARIMA	16181.119	13375.235	23.921
受约束组合	12017.888	10078.790	17.485

5.4 季节锚定组合与经验区间

组合在原尺度直接最小化滚动预测误差。设第 i 条回测任务上模型 j 的预测为 p_{ij} ，复杂度系数为 c_j ，则权重由

$$\begin{aligned} \min_w \quad & \frac{1}{N \text{Var}(y)} \sum_{i=1}^N \left(y_i - \sum_j w_j p_{ij} \right)^2 + \eta \sum_j c_j w_j^2, \\ \text{s.t.} \quad & w_j \geq 0, \quad \sum_j w_j = 1, \quad w_{SN} \geq 0.25, \end{aligned} \quad (15)$$

其中， $N = 78$ ，第一项用实际值方差消除销售额量纲； c_j 随候选结构复杂度递增，使复杂模型承担更高权重代价；主设定取 $\eta = 0.02$ 。非负且和为一保证结果仍是可解释的加权平均， w_{SN} 的下限把季节锚变成约束而不是事后描述。因为本题只有 3 个完整训练周期，牺牲少量样本内最优性来限制复杂模型权重，更符合部署时对稳定性的要求。

表5显示，权重集中在阻尼 ETS 与季节朴素，谐波岭补充平滑季节形状，SARIMA 的边际增益不足而被压至近零。

表 5 主组合权重、锁定参数与模型职责

模型	权重	锁定参数	组合职责
季节朴素	0.25000	去年同月	稳定季节锚
阻尼 ETS	0.49326	$\phi = 0.98$	水平与阻尼趋势
谐波岭回归	0.25674	$K = 2, \lambda = 1.0$	平滑季节形状
低阶 SARIMA	≈ 0	$(0, 1, 1)(1, 0, 0)_{12}$	相关结构候选

权重灵敏度同时扰动季节锚下限与惩罚强度。预设的 9 种组合中，训练期权重虽有变化，独立复算的封存测试均保持主指标 3 项全胜、季度 4 季全胜；主设定没有因测试年表现而改选。

区间校准使用滚动组合的绝对对数误差

$$a_i = |\log(1 + y_i) - \log(1 + \hat{y}_i)|. \quad (16)$$

我们最初打算对 1 至 12 步分别估计经验分位数，但可用残差数由 12 条递减至 1 条，第 12 步无法稳定估计尾部。因此将步长合并为 1-3、4-6、7-12 三组，校准样本数分别为 33、24、21。若组 g 的置信水平 c 对应分位数为 $q_{g,c}$ ，则

$$\mathcal{I}_{g,c}(\hat{y}) = [\max\{0, \exp(\log(1 + \hat{y}) - q_{g,c}) - 1\}, \exp(\log(1 + \hat{y}) + q_{g,c}) - 1]. \quad (17)$$

其中，乘性构造让高销售月份获得更宽的风险带，并把下界截断为非负；该区间来自短样本经验残差，不解释为严格参数置信区间。

5.5 封存测试、部署门槛与残差诊断

锁模后才用 MSE、MAE 与 MAPE 计算测试误差；测试月实际销售额均为正，故 MAPE 不需要零值替代。

部署门槛在查看测试结果前固定。令 $\mathcal{M} = \{MSE, MAE, MAPE\}$ ，季度集合为 $\mathcal{Q}$ ，部署指示量写为

$$D_M = \sum_{m \in \mathcal{M}} \mathbf{1}(L_m^C < L_m^{SN}), \quad D_Q = \sum_{q \in \mathcal{Q}} \mathbf{1}(MAE_q^C < MAE_q^{SN}),$$

$$D = \mathbf{1}\{D_M \geq 2\} \mathbf{1}\{D_Q \geq 3\}, \quad \hat{f}_{deploy} = \begin{cases} \hat{f}_C, & D = 1, \\ \hat{f}_{SN}, & D = 0. \end{cases} \quad (18)$$

其中， D_M, D_Q 分别是主指标和季度 MAE 的胜出数， C 表示锁定组合， SN 表示季节朴素。该门槛只在组合与硬基线之间做一次部署验收，不允许依据 2025 年从全部候选中重新择优；否则唯一测试集会被二次用于调参。

表6给出封存测试结果。组合的 MSE、MAE、MAPE 均小于季节朴素，季度 MAE 也在全部 4 个季度胜出，故 $D = 1$ ，后续采用受约束组合。

表 6 封存测试年主指标比较

模型	MSE	MAE	MAPE (%)
受约束组合	141848378.568	9583.563	16.367
季节朴素	358424462.499	15444.178	24.865

组合相对基线将 MSE、MAE、MAPE 分别降低 60.42%、37.95%、34.17%，测试 RMSE 为 11910.012。图9显示误差并非均匀分布：2025 年 8 月实际销售额为 62837.848，预测为 41057.274，低估 21780.574，是全年最大绝对误差。




图 9 封存测试年的实际值、组合预测与经验区间

残差诊断解释了点预测优势仍不能消除的风险。图10中，残差均值为 +4846.247，12 个月里有 8 个月被低估；四阶 Ljung–Box 检验 [8] 的 p 值为 0.2477，未检出显著剩余自相关，但样本量不足以支持强白噪声判断。




图 10 封存测试残差的时序、自相关与分位诊断

经验区间的实际覆盖率分别为 75.00% 和 83.33%，低于对应名义水平。这组结果支持把组合点预测用于部署，也要求把区间称为短样本风险带。部署通过后，模型可在 2022 年 1 月至 2025 年 12 月的 48 个月数据上重拟合状态与系数，但阻尼、谐波阶数、岭惩罚和组合权重保持锁定，再向下一章提供可加总的月度总量锚。

六、总量一致的 2026 层级预测与经营动作

6.1 总量硬锚与层级份额收缩

本问不再改动上一章已经通过封存测试的总量模型，而是把每个月的销售总额分配到区域、产品、客户和发货层级。对任一维度，记历史月份 t 中层级 g 的销售额为 $x_{g,t}$ ，总销售额为 Y_t ，则历史份额 $s_{g,t} = x_{g,t}/Y_t$ 。预测阶段把长期份额 L_g 、近窗份额 R_g 与同月季节份额 $M_{g,m(t)}$ 收缩为

$$\begin{aligned}
 B_{g,t} &= \eta R_g + (1 - \eta) M_{g,m(t)}, \\
 \rho_g &= \frac{12}{12 + \kappa(1 + CV_g^2)}, \\
 q_{g,t} &= \rho_g B_{g,t} + (1 - \rho_g) L_g, \\
 \hat{s}_{g,t} &= \frac{\max(q_{g,t}, 0)}{\sum_h \max(q_{h,t}, 0)}.
 \end{aligned} \tag{19}$$

其中， η 控制近期信息相对同月季节信息的权重， κ 控制向长期结构收缩的强度， CV_g 是历史月度份额变异系数， ρ_g 是局部信息保留系数。因为本题层级越细，份额波动和零

销售月份越容易放大, CV_g 增大时 ρ_g 自动减小, 偶然的大额订单便不会直接变成下一年的结构判断。

起初的做法是分别拟合区域、产品大类、产品子类、客户细分和发货模式的月度总额模型, 后来发现各层级最多只有 48 个月, 产品子类份额变异系数中位数为 0.684、最大为 2.147, 单个子类最多出现 16 个零销售月。这些现象意味着独立时序既会放大稀疏层级的方差, 也无法自然回到同一个总量, 因此改用总量硬锚加份额收缩。锁定参数取 $\eta = 0.75$ 、 $\kappa = 12$, 同月季节份额权重相应为 0.25; 参数只由 2024 年校准误差确定, 未用 2025 年重新挑选。

层级点预测与可加总风险边界统一写为

$$\hat{x}_{g,t} = \hat{s}_{g,t} \hat{Y}_t, \quad \hat{x}_{g,t}^{(b)} = \hat{s}_{g,t} \hat{Y}_t^{(b)}, \quad b \in \{80L, 80U, 95L, 95U\}. \quad (20)$$

其中, $\hat{Y}_t$ 是问题三给出的月度总量点预测, $\hat{Y}_t^{(b)}$ 是相应边界。归一化保证同一维度的份额非负且和为一, 因而点预测和各条边界都严格加回总量; 这种协调口径与层级预测强调的跨层加总约束一致 [10]。这些边界没有联合计入份额随机性, 只表示给定预测份额后的可加总风险边界, 不能解释为层级对象的完整概率区间。

产品层级还需要消除大类表与子类表之间的矛盾。令 $\hat{s}_{k,t}^C$ 为大类 k 的预测份额, $\hat{u}_{j|k,t}$ 为子类 j 在该大类内部的条件份额, 则

$$\hat{s}_{j,t}^{SC} = \hat{s}_{k,t}^C \hat{u}_{j|k,t}, \quad \sum_{j \in k} \hat{s}_{j,t}^{SC} = \hat{s}_{k,t}^C. \quad (21)$$

其中, $\hat{u}_{j|k,t}$ 在父级内部归一化。这样子类先加到所属大类, 大类再加到月度总量, 避免两套独立份额表给出互相冲突的经营口径。

6.2 回测改进与 2026 年总量节奏

固定复制去年同月份额虽然简单, 却只保留单月结构。锁定后的收缩模型在 2025 年五维平均份额 WAPE 为 29.015%, 固定份额基线为 39.585%, 改善 10.570 个百分点; 其中产品子类仍有 44.803% 的份额 WAPE, 说明协调后的细层结果可用于方向与容量安排, 不宜把小子类名次写成刚性承诺。近期权重与收缩强度的 9 组扰动使 2025 年平均份额 WAPE 落在 29.010% 至 31.031%, 全部低于同一基线。

全年点预测为 791951.82, 95% 可加总风险边界为 [454803.67, 1379541.60]; 季度销售额逐季抬升, 第四季度占全年点预测的 38.30%, 经营资源不能按四季平均摊派。问题三封存测试中, 月度 95% 风险带的实际覆盖率为 83.33%, 低于名义水平; 季度和全年边界又是月度上下边界分别相加的结果, 没有单独校准联合覆盖率, 故表 7 只把它们用于资源压力测试, 不作概率承诺。

表 7 2026 年季度总量预测及可加总风险边界（销售额单位：万）

季度	点预测	80% 风险边界	95% 可加总风险边界
2026Q1	12.35	[9.21, 16.55]	[7.00, 21.77]
2026Q2	15.82	[12.40, 20.19]	[9.44, 26.51]
2026Q3	20.70	[16.18, 26.47]	[11.78, 36.37]
2026Q4	30.33	[23.71, 38.80]	[17.26, 53.31]

表7中的旺季抬升在图11左侧表现为年末扇形带同步变宽。五个维度逐月汇总的最大误差为 5.82×10^{-11} ，产品大类与子类的最大父子协调误差为 1.46×10^{-11} ，均表明数值误差没有破坏经营口径。




图 11 2026 年总量风险带与层级机会—把握度矩阵

6.3 机会—把握度评分与情景边界

预测规模不能单独决定投入强度。对每个真实层级对象，机会分 O_g 综合预测增量、预测规模和历史增长，把握度分 C_g 综合问题二证据、份额稳定性和相对不确定性的逆序分位秩：

$$\begin{aligned} O_g &= 0.45P_{\Delta,g} + 0.35P_{S,g} + 0.20P_{G,g}, \\ C_g &= 0.45E_g + 0.30P_{V,g} + 0.25P_{U,g}. \end{aligned} \tag{22}$$

其中， $P_{\Delta,g}$, $P_{S,g}$, $P_{G,g}$ 分别是维度内增量、规模和历史增长的分位秩， E_g 是双证据得分， $P_{V,g}$ 与 $P_{U,g}$ 分别奖励稳定份额和较低不确定性。机会分与把握度分均以 60 分划分高低，因而高销售容量但缺少驱动证据的对象仍可能落入小步试点区。

我们最初考虑按权重比例缩放已有总分，但发现总分无法还原机会分和把握度分的各三个组件，这种缩放会把口径偏移误当成对象翻转。因此从 31 个对象的原始分项重

建分位秩，基准机会分与把握度分的最大复现误差均为 0；固定机会阈值后，将四组机会权重、四组把握度权重与三档把握度阈值组合成 48 组全网格。

全网格入选频率把稳定对象与临界对象直接分开：Technology、Accessories、Chairs、Phones、Storage、Tables 和 East 在 48 组中全部入选；West 和 Binders 分别入选 44 组和 40 组；Central 仅入选 21 组，Consumer 与 Second Class 均仅入选 16 组。全网格中核心清单规模介于 8 与 17 个对象之间，最低仅保留基准清单的 57.14%，故全入选对象可用于基准资源配置，未全入选对象必须等实际增量或容量信号触发后再追加。

分类稳定不等于总量情景下的名次稳定。图11右侧的 31 个层级对象中，点预测与 95% 下侧风险边界机会分的 Spearman 相关为 0.701，前 10 项仅重合 5 项；West 由点预测的第 14 位升至下侧风险边界的第 1 位。这一反转使 West 在悲观情景中承担基本盘防守，基准情景的新增资源则先投向 East 及全网格稳定产品。

6.4 分层经营动作

表8从稳定核心、高频入选和低频敏感对象中抽取代表，将基准销售额与悲观边界配对后再设触发动作。证据等级 A 表示全网格入选，B 表示高频入选但存在翻转，C 表示对权重或阈值较敏感；括号内同时给出真实入选次数，不将等级解释为概率。

表 8 代表对象的 2026 年销售额边界与触发动作（单位：万）

对象	基准销售额	悲观边界	触发动作	证据等级
Phones	11.50	6.60	超基准再扩容	A（48/48）
Storage	7.63	4.38	近下界收紧补货	A（48/48）
East	23.29	13.37	下行时仅留可撤预算	A（48/48）
West	25.69	14.75	悲观保供，超基准扩展	B（44/48）
Central	16.66	9.57	增量兑现后追加	C（21/48）

Phones 的旺季上侧风险边界较点预测高约 3.32 万，这段容量区间适合检验仓储、采购额度和供应响应能否承接销售额波动，但数据没有销量与库存字段，不能换算成安全库存件数。物流侧还核对了 42 条异常日期：年份修正与异常置缺口径的订单簇置换 p 值分别为 0.108 和 0.052，两种处理都没有形成稳定驱动证据。经营执行可据此设置三档口径：基准情景围绕 East 与稳定核心产品配置资源，悲观情景收紧可撤销预算并守住 West，旺季压力情景则以 Phones 上侧风险边界检验销售额承接能力；Central 等敏感项只有在评分与实际增量同时满足条件时才追加投入。该分档只调整资源承诺强度，不虚构利润最优、价格弹性或库存件数。

七、从数据口径到决策稳健性的跨问题检验

单问指标只说明局部模型是否可用，跨问题审计则检查上游口径、参数和不确定性传到下游后会不会改变经营结论。表9只保留影响任务链衔接的核验结果，预测误差、因素效应和层级数值的完整解释见对应问题章节。

表 9 跨问题口径、参数与决策审计表

传递链路	审计设置	核验结果	下游约束
治理到识别	疑似复制保留或删除；异常发货日期修正或置缺	总销售额变化 0.0124%，履约效应量差 0.000131，显著性结论一致	销售结构沿用去重主口径，物流只作双口径关联解释
识别到策略	平滑、树复杂度与跨年判据构成 81 组网格	三项产品因素均为 81/81 入选，区域仅为 54/81	产品信号进入重点动作，区域只保留次级提示
验证到应用	2025 验证集复用；逐日在线特征；固定 2024-12-31 离线预测	2025 年已用于时间外评估与灵敏度诊断，不再视为完全未触碰的外部测试	逐日识别可使用当日之前已实现记录；若在年末一次性预测下年全年，须将历史特征截止日固定为 2024-12-31 并重新验证
预测到部署	季节锚下限与复杂度惩罚形成 9 组扰动	各设定均保持主指标 3/3、季度 4/4 优于基线	采用训练期锁定组合，不按测试年重新挑权重
总量到层级	近期权重与收缩强度形成 9 组扰动	份额 WAPE 为 29.010%–31.031%，低于固定份额的 39.585%	收缩优势稳定，细层名次仍受总量情景约束
层级到预算	多维点预测与区间边界逐月回加	最大总量误差 5.82×10^{-11} ，产品父子误差 1.46×10^{-11}	各业务预算共享同一总量，区间仅作可加总风险边界

我们最初以 0.75 的跨年方向一致率门槛把区域列入核心因素，但把门槛提高到 1.00 后，区域因实际一致率仅为 0.75 而退出；完整网格又出现重要性方向翻转，因此将区域降为次级信号，避免不稳定地理标签直接放大为强投入建议。

模型的优点在于四问共享可追溯口径：订单簇控制明细相关性，时间外基线约束预

测复杂度，总量锚与父子协调保证预算可加总；任何信号只有经口径、参数和时间检验后才提高策略强度。这种把预测精度与层级一致性同时纳入评价的做法，也符合时间序列部署和层级预测的基本要求 [9, 10]。

局限来自数据长度与字段边界：短月度序列难以充分校准远期区间，细层份额误差没有与总量误差建立联合分布；利润、成本、折扣、促销、销量和库存字段缺失，又使稳定关联不能转写为干预因果。模型适合滚动更新销售额与容量优先级，不适合承诺利润最优、价格弹性或安全库存件数。

八、零售预测结论、适用边界与推广

8.1 四问结论

问题一把最初按 9800 条明细计订单的口径改为按订单号去重，确认实际订单数为 4921，并发现销售额最高一成明细贡献 60.40%、第四季度贡献 38.52%，销售呈现交易长尾与年末集中的双重结构。

问题二最初把区域列入核心，完整参数网格复核后只保留产品历史价值层、产品大类和产品子类，三者均在 81/81 组中入选；区域降为次级地理信号，只在 54/81 组中入选。

问题三曾纳入低阶 SARIMA 候选，但有候选产生非有限预测且最终权重接近零，故部署由季节朴素、阻尼 ETS 与谐波岭构成的受约束组合；封存期 MAPE 为 16.367%，低于季节朴素的 24.865%。

问题四放弃细层级独立建模后采用总量锚定的份额收缩，验证期平均份额 WAPE 由固定份额的 39.585% 降至 29.015%；下一年度销售额点预测为 791951.82，全年可加总风险边界为 [454803.67, 1379541.60]。2025 年封存测试的 95% 经验区间覆盖率仅为 83.33%，该边界不作严格概率保证。

8.2 适用边界

这些结论适用于当前企业既有类别、相同订单口径和相近经营环境。数据缺少利润、成本、折扣、促销、销量与库存，产品和区域结果只能解释销售关联与容量优先级；可加总风险边界未联合刻画份额误差，细层级名次也不宜转化为刚性预算或因果承诺。2026 年外推还以表1中的季节位置与份额机制延续假设为前提；出现结构突变时，须转入滚动重估。

8.3 推广方向

若后续接入价格、促销、库存、利润和门店覆盖数据，可在保持时间外切分与层级加总约束的前提下，扩展为需求弹性、利润目标和库存服务水平的联合决策；若出现新区域或新品类，则应先设置“其他/新层级”份额，再随新增观测滚动更新总量模型与收缩权重。

参考文献

- [1] TUKEY J W. Exploratory Data Analysis[M]. Reading, MA: Addison-Wesley, 1977.
- [2] KRUSKAL W H, WALLIS W A. Use of ranks in one-criterion variance analysis[J]. Journal of the American Statistical Association, 1952, 47(260): 583–621.
- [3] BENJAMINI Y, HOCHBERG Y. Controlling the false discovery rate: A practical and powerful approach to multiple testing[J]. Journal of the Royal Statistical Society: Series B (Methodological), 1995, 57(1): 289–300.
- [4] FRIEDMAN J H. Greedy function approximation: A gradient boosting machine[J]. The Annals of Statistics, 2001, 29(5): 1189–1232.
- [5] GARDNER E S, MCKENZIE E. Forecasting trends in time series[J]. Management Science, 1985, 31(10): 1237–1246.
- [6] HOERL A E, KENNARD R W. Ridge regression: Biased estimation for nonorthogonal problems[J]. Technometrics, 1970, 12(1): 55–67.
- [7] DUAN N. Smearing estimate: A nonparametric retransformation method[J]. Journal of the American Statistical Association, 1983, 78(383): 605–610.
- [8] LJUNG G M, BOX G E P. On a measure of lack of fit in time series models[J]. Biometrika, 1978, 65(2): 297–303.
- [9] HYNDMAN R J, ATHANASOPOULOS G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021.
- [10] HYNDMAN R J, AHMED R A, ATHANASOPOULOS G, et al. Optimal combination forecasts for hierarchical time series[J]. Computational Statistics & Data Analysis, 2011, 55(9): 2579–2589.